Lab1 实验报告

1. 实验目的

• openrefine工具的数据过滤、聚类,文本过滤,数据分组,数据转换,数据输出以及正则表达式的应用等.

2. 实验环境

- win10 64位
- java8
- openrefine

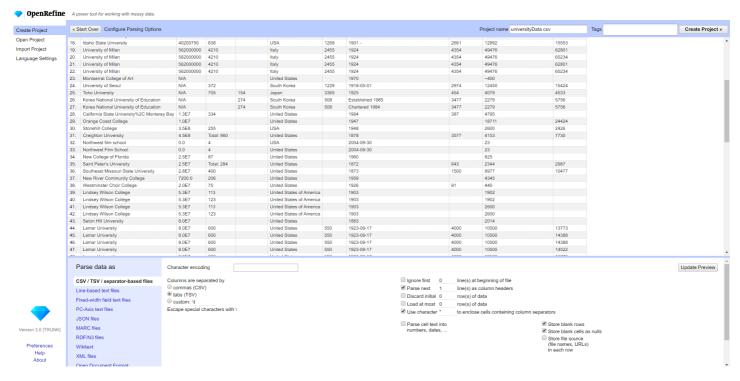
3. 实验步骤

• 首先使用命令行检查本机是否安装了java.可以看到本机已经安装了java的10.0.1的版本.

• 前往openrefine官网下载最新版的openrefine3.0版本,解压后运行,发现依然弹出安装java的窗口.在检查下载没有问题之后,我安装了弹出窗口的java8.0版本.

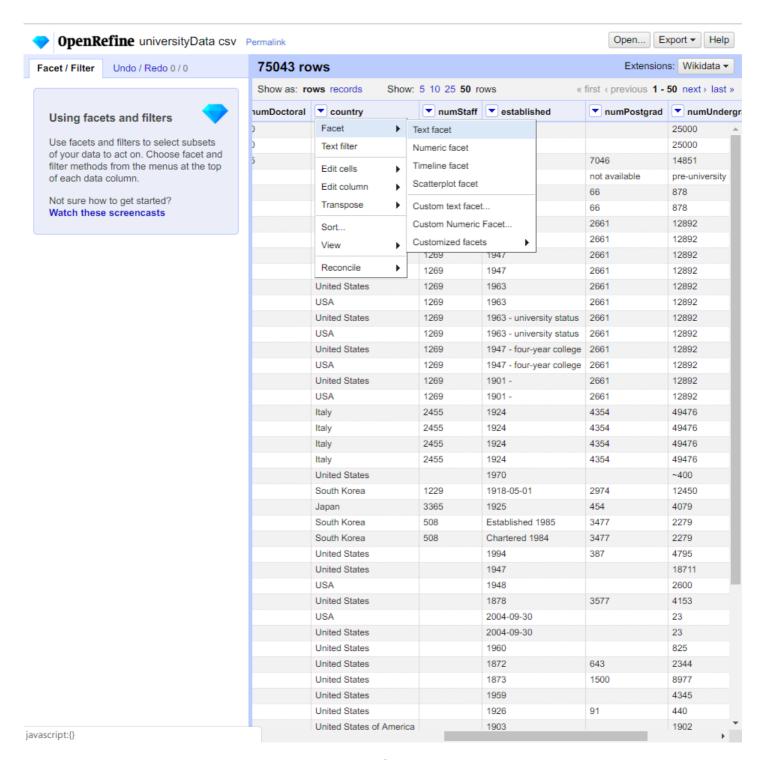
```
Microsoft Windows [版本 10.0.17134.285]
(c) 2018 Microsoft Corporation。保留所有权利。
C:\Users\HASEB>java -version
java version "1.8.0_181"
Java (TM) SB Runtime Environment (build 1.8.0_181-b13)
Java HotSpot(TM) Client VM (build 25.181-b13, mixed mode)
C:\Users\HASEB>_
```

• 在重新安装完成后,根据群内的同学的反映,我替换掉了openrefine中的一个文件从而能够在win10的64位中文版系统中顺利打开openrefine界面.打开后,根据实验指南中的网址下载了数据集,并将数据集导入了openrefine中.



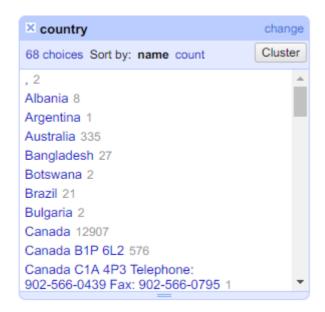
使用openrefine打开数据集

• 首先使用text facet功能来对特定文本的值进行分组归类统计.在country列中执行text facet操作.



text facet

• 对country列进行text facet操作后,openrefine自动将country列中的国别进行了聚类操作,并将结果显示在了左边栏中.

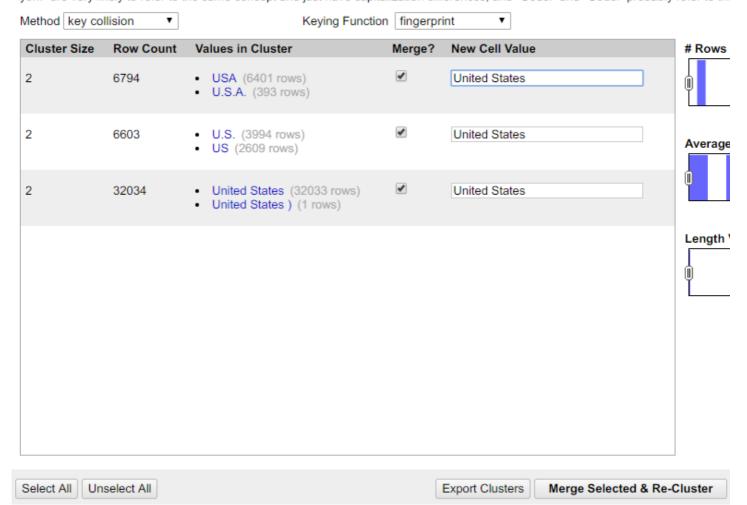


text facet结果

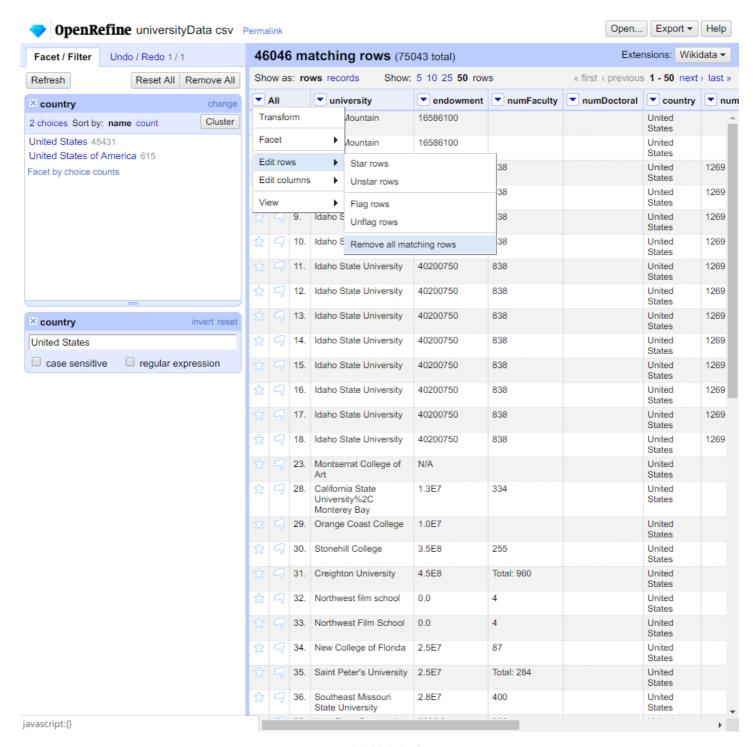
• 在聚类完成后,发现类别中对于美国国名的描述出现了不同种类的偏差.为了将描述进行统一,按照实验指南,我对这些类别进行了merge操作.

Cluster & Edit column "country"

This feature helps you find groups of different cell values that might be alternative representations of the same thing. For example, the york" are very likely to refer to the same concept and just have capitalization differences, and "Gödel" and "Godel" probably refer to the

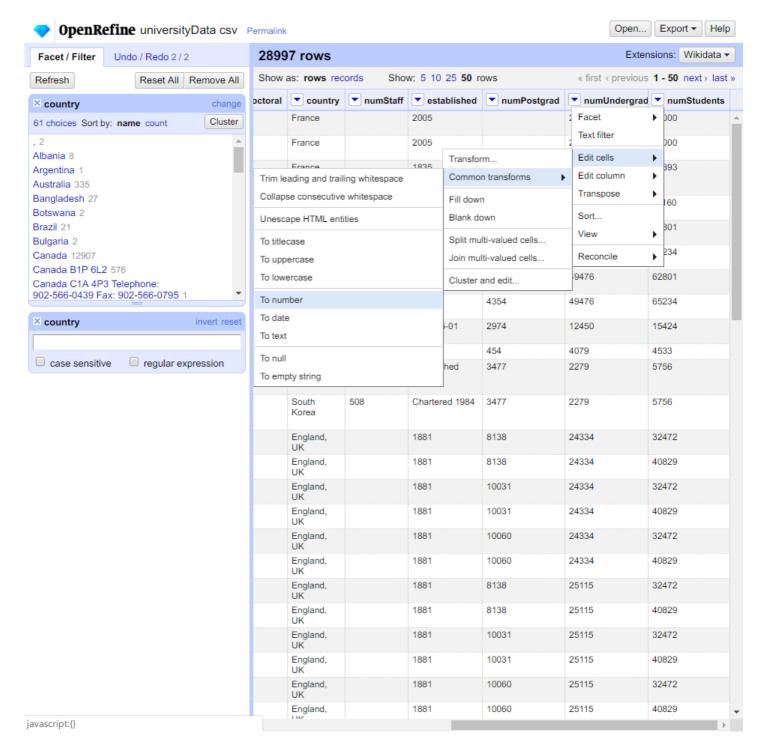


接着对样本进行文本过滤.假设我们不需要来自美国大学的信息.我使用text fliter的功能,输入united states,并使用edit rows中的remove all matching rows来删除匹配到的所有行.



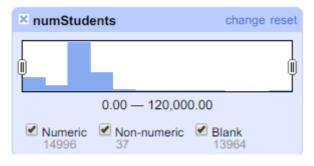
删除某类样本

• 接着使用numeric facet对数值型数据进行分组.由于numStudents中的数据是使用文本字符串存储的数值型数据, 因此我们使用common transform中的to number功能将此类数据转换为数值型数据.



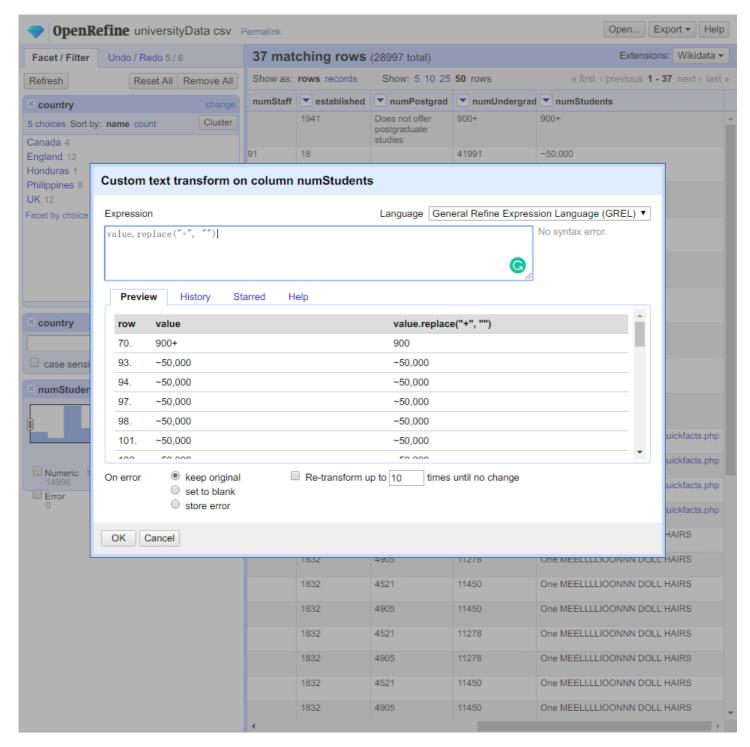
将文本转换成数字

• 此时再使用numeric facet功能对数据集中的数据进行分析.



对转换后的数据进行统计

• 可以看到数据集中出现了一些转换后依然是非数值型的数据.取消勾选Numeric以及Blank选项.并使用edit cell中的transform功能将修改这些数据使其能够符合格式要求.



修改不合规范的数据

- 修改后重新进行类数据格式的转换,将依然不符合格式要求的非数值型数据删除.
- openrefine1还有很方便的撤销操作,在左边栏切换到undo/redo标签即可通过点击操作列表回退操作

 Create project 1. Mass edit 45431 cells in column country 2. Remove 46046 rows 3. Text transform on 14996 cells in column numStudents: value.toNumber() 4. Edit single cell on row 70, column numStudents 5. Edit single cell on row 70, column numStudents Text transform on 1 cells in column numStudents: grel:value.replace("+", "") Edit single cell on row 93, column numStudents 8. Text transform on 8 cells in column numStudents: grel:value.replace("~", ""); value.replace",", "") 9. Text transform on 1 cells in column numStudents: value.toNumber() 10. Remove 36 rows

方便的撤销操作列表

4. 实验总结

在本次实验中我接触了一个可以对数据集进行一定程度预处理的软件openrefine,在以前我对数据进行预处理的时候都是使用python自带的pandas包进行的,由于我本人的操作不熟练导致效率相当的低下.而相对的,在openrefine中进行简答的数据预处理则非常方便.不过,这同时也要求我对这款软件进行更加深刻的了解.

5. 操作习题

举例说明正则表达式?

^\d+(\.\d+)?

- # 用来匹配个位数的实数
- # ^\d定义了以单个数字开始
- #? 设置括号内的选项是可选的
- #\. 匹配 "."
- # \d 表示在"."后面接数字

简述正则表达式的作用

正则表达式是用来描述或者匹配一系列符合某个句法规则的字符串的单个字符串.它通常被用来检索和/或替换那些符合某个模式的文本内容.

通过操作,举例说明openrefine中正则表达式的使用

使用正则表达式选取大学创始在2000年到2006年之间的学校

